MÁSTER EN IA · UAI · TÓPICOS AVANZADOS EN IA 2

Taller · Destilación en pequeño

Pauta del taller · 15 horas en clases · entrega individual · un LLM grande enseña a un modelo de 135 M parámetros que corre en tu CPU

Qué vas a hacer. Durante 15 horas de clase (cinco bloques de 3 horas) vas a construir, medir y mejorar un modelo destilado para un dominio que tú eliges, y entregarás un informe individual con tus experimentos. El ciclo técnico tiene seis etapas y una corrida completa toma unos 10 minutos: el **profesor** (API de OpenAI) escribe preguntas y respuestas de un dominio; el **estudiante** (SmolLM2-135M, arquitectura Llama) rinde un examen; lo entrenas con LoRA sobre las respuestas del profesor; vuelve a rendir el examen; comparas antes y después con un gráfico y ejemplos lado a lado.

0 · Antes del taller (5 minutos, requiere internet)

Requisito	Detalle
Computador	Cualquier notebook de los últimos 6 años, **sin GPU**. 8 GB de RAM alcanzan. 2 GB de disco libres.
Python 3.10 a 3.13	Mac: `brew install python@3.12` · Windows: python.org (marca "Add to PATH") · Linux: `apt install python3.12-venv`
Clave de OpenAI (opcional)	Con clave, el profesor es real (costo < US$ 0,05 por corrida). Sin clave o sin internet, el taller corre igual en modo simulado.
Kit del taller	Carpeta `taller-destilacion/` : `destila.py` (todo el código) · `taller_destilacion.ipynb` · `PLANTILLA_INFORME.md` · `requirements.txt` · `.env` · `README.md`

1 · Instalación

```
# Mac / Linux
cd taller-destilacion
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt

# Windows (PowerShell)
cd taller-destilacion
py -3.12 -m venv .venv
.\.venv\Scripts\Activate.ps1
pip install -r requirements.txt
```

La instalación descarga ≈ 800 MB (PyTorch para CPU). Si PowerShell bloquea el script de activación: `Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass`.

Clave de OpenAI: abre el archivo `.env` y escribe `OPENAI_API_KEY=sk-...` en una sola línea, sin comillas. Es la única edición necesaria. Si no tienes clave, deja el archivo como está.

2 · Prueba rápida (1 minuto, sin clave ni internet)

```
python destila.py --sin-internet
```

Debe terminar con una línea `RESULTADO: nota 1 → 9.x`. Eso confirma que la instalación funciona. Usa un profesor simulado y un modelo diminuto creado en el momento: sirve para validar el flujo, no la calidad.

3 · Correr el taller

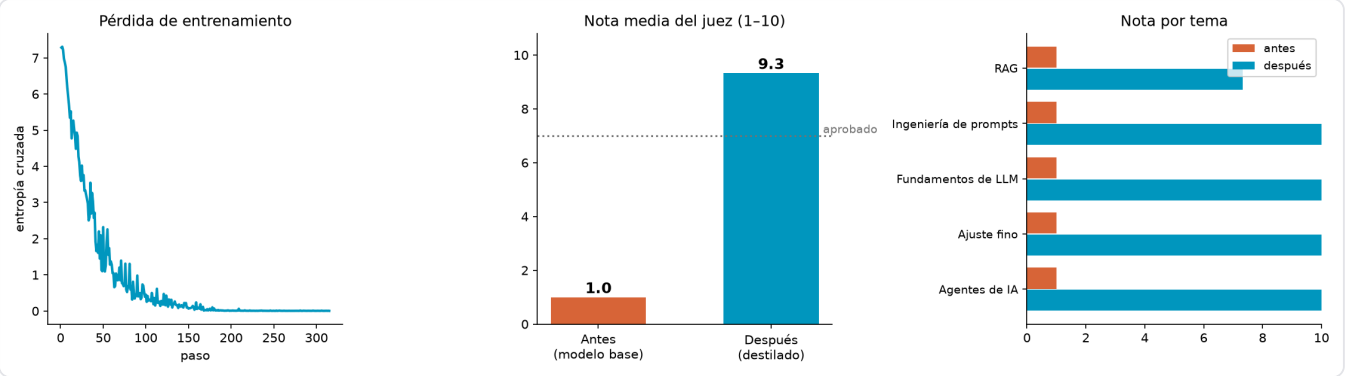
Forma	Comando
Notebook paso a paso (recomendado)	`jupyter notebook taller_destilacion.ipynb` → ejecutar celda por celda
Todo de una vez	`python destila.py`
Sin internet en la sala	`python destila.py --sin-internet` · en el notebook: `SIN_INTERNET = True`
Estudiante más capaz (2–3× más lento)	`python destila.py --estudiante HuggingFaceTB/SmolLM2-360M-Instruct`

La primera corrida real descarga el estudiante (270 MB) desde Hugging Face y queda en caché.

Las seis etapas y su tiempo aproximado en CPU

#	Etapa	Qué ocurre	Tiempo
1	Configurar	Lee `.env`, elige profesor (OpenAI u offline) y dispositivo	segundos
2	Generar datos	El profesor escribe 72 preguntas sobre 6 temas y las responde; 12 quedan como examen fijo	1–2 min
3	Cargar estudiante	Descarga SmolLM2-135M y agrega LoRA (≈ 1 % de parámetros entrenables)	1 min
4	Examen antes	El estudiante responde 12 preguntas; el juez califica 1–10 contra la referencia	1–2 min
5	Entrenar	SFT con LoRA: 60 ejemplos × 3 épocas (la pregunta se enmascara, solo se aprende la respuesta)	2–5 min
6	Examen después	Nota nueva, gráfico, tabla y ejemplos lado a lado en `salidas/`	1–2 min

4 · Qué vas a ver



Ejemplo de `salidas/resultados.png` en modo simulado: pérdida de entrenamiento, nota media antes y después, nota por tema. Con el estudiante real y el profesor real las curvas son más modestas: espera subir de ≈ 3–4 a ≈ 6–7 en una corrida de 10 minutos.

Archivo	Contenido
`datos/entrenamiento.jsonl` · `datos/examen.jsonl`	pares pregunta-respuesta del profesor · examen fijo
`salidas/examen_antes.jsonl` · `examen_despues.jsonl`	respuesta del estudiante, nota y comentario del juez por pregunta
`salidas/entrenamiento_log.jsonl`	pérdida por paso
`salidas/checkpoint/`	adaptador LoRA entrenado (≈ 5 MB): el "modelo destilado"
`salidas/resultados.png` · `resultados.md`	gráfico · tabla y 5 ejemplos lado a lado

5 · Plan de trabajo · 15 horas en cinco bloques

Bloque	Objetivo	Actividades	Hito al cierre
1 · 3 h	Instalar y entender el ciclo	Instalación · `--sin-internet` · corrida completa con el profesor real · lectura guiada de `destila.py` (las seis funciones) · discusión: destilación de caja negra, examen fijo, juez LLM	Corrida base funcionando; `resultados.png` de la configuración por defecto
2 · 3 h	Tu dominio y tus datos	Elegir un caso propio (puede ser ficticio) · definir `dominio` y `temas` · regenerar datos · leer 10 respuestas del profesor y corregir prompts · estimar costo	Secciones 1 y 2 del informe; `datos/` propio
3 · 3 h	Línea base y experimentos	Nota base del estudiante · al menos 3 corridas cambiando una variable por vez (datos, épocas, tasa de aprendizaje, rango LoRA) · registrar tiempos · detectar sobreajuste	Tabla de experimentos con ≥ 3 filas
4 · 3 h	Auditar al juez y cerrar la mejor corrida	Calificar a mano 10 ítems del examen y comparar con el juez · ajustar el prompt del juez si corresponde · (opcional) SmolLM2-360M · elegir configuración final	Sección 5 del informe; modelo final guardado en `salidas/checkpoint`
5 · 3 h	Demostrar y reflexionar	Demostración de 5 minutos por persona (base vs. destilado, dentro y fuera del dominio) · redacción de la reflexión · cierre del informe	Informe PDF + carpeta del proyecto entregados

Si el curso trabaja en sesiones de 4 horas, los bloques 1–2 y 3–4 se agrupan en dos sesiones y el bloque 5 ocupa la mitad de una tercera.

6 · Entrega individual

Qué se entrega: (1) informe en PDF siguiendo `PLANTILLA_INFORME.md` (6–10 páginas) y (2) carpeta del proyecto comprimida: `destila.py` modificado, notebook ejecutado, `datos/` y `salidas/`. **Sin** el archivo `.env`.
Cuándo: al cierre del bloque 5 (fecha que indique el profesor). **Atraso:** descuenta 1,5 puntos por día hasta nota 1,0. Nota mínima de aprobación: 4,0.

Trabajo individual: puedes conversar con compañeros, pero el dominio, los experimentos, la auditoría del juez y el informe son propios. Declara en el anexo el uso de asistentes de IA en la redacción.

Rúbrica (propuesta · 100 puntos → nota 1,0 a 7,0)

Criterio	Pts	Logrado (puntaje completo)	Insuficiente
Caso y datos del profesor	15	Dominio claro y justificado; datos propios; revisión humana de 10 respuestas con criterio	Dominio por defecto o sin revisión de datos
Línea base	10	Nota base medida e interpretada con ejemplos	Sin medición antes de entrenar
Experimentos	25	≥ 4 corridas, una variable por vez, tabla completa, sobreajuste analizado con evidencia	Una sola corrida o cambios sin registro
Auditoría del juez	15	10 ítems calificados a mano, acuerdo cuantificado, sesgos identificados	Se acepta la nota del juez sin revisarla
Modelo final y demostración	15	Resultados reproducibles, 5 preguntas lado a lado, limitaciones honestas	Sin demostración o resultados no reproducibles
Reflexión	15	Decisión destilar vs. API argumentada con costo, privacidad, calidad, licencias y riesgos	Opinión general sin vínculo con los resultados
Calidad del informe y del código	5	Claro, ordenado, reproducible, sin claves en el entregable	Desordenado o no reproducible

7 · Si algo falla

Síntoma	Solución
`401 invalid_api_key`	Clave mal pegada o una `OPENAI_API_KEY` antigua en la terminal (`echo $OPENAI_API_KEY`). `.env` tiene prioridad; prueba con una clave nueva.
`404 model not found`	Tu cuenta no tiene ese modelo: en `.env` agrega `OPENAI_MODEL=gpt-5-mini`
No descarga el modelo	Red que bloquea Hugging Face: usa `--sin-internet` o descarga desde otra red (queda en caché)
Muy lento	Baja `n_entrenamiento` a 40 y `epocas` a 2 en `CONFIG`
`No module named torch`	Activa el entorno virtual (`source .venv/bin/activate`) y elige ese kernel en Jupyter
Respuestas repetitivas o vacías	Normal en un modelo de 135 M con pocos datos: sube `n_entrenamiento` o usa SmolLM2-360M

8 · Ideas para la discusión de cierre

- Destilación de caja negra: el estudiante imita **respuestas**, no probabilidades. Su techo es la calidad y diversidad de lo que escribe el profesor.
- El examen fijo y separado es lo que hace comparables las notas. Sin línea base no sabes si entrenar ayudó.
- El juez es otro LLM: escala la evaluación, pero hay que auditar una muestra a mano.
- Licencias: SmolLM2 es Apache 2.0; los términos de OpenAI restringen usar sus salidas para crear modelos que compitan con OpenAI. Uso educativo e interno, y revisión legal antes de producción.
- Para un caso real: modelo estudiante de 1–4 B, cientos o miles de ejemplos, varias rondas con currículo adaptativo y GPU (ver el repositorio `slm-autonomo`).