Informe individual · Taller de destilación en pequeño

Un LLM grande (profesor, API de OpenAI) enseña a SmolLM2-135M en CPU
Tópicos Avanzados en IA 2 · Máster en IA · UAI

Nombre	Fecha de entrega	Dominio
Richard Howell	19-10-2026	Configuración por defecto del profesor: IA generativa explicada a ejecutivos de empresas chilenas

1. Caso y dominio

Siguiendo la indicación del profesor para esta entrega, se corrió el taller con el dominio y los temas por defecto, sin un caso de negocio propio: un asistente que explica conceptos de IA generativa a ejecutivos de empresas chilenas, con ejemplos de negocio. Un asistente así serviría, por ejemplo, a un área de transformación digital que recibe preguntas repetidas de gerentes (qué es RAG, cuándo ajustar un modelo, cómo evaluarlo).

CONFIG usada (destila.py)

```
"dominio": "asistente que explica conceptos de inteligencia artificial generativa a ejecutivos de empresas chilenas, con ejemplos de negocio",
"temas": ["Fundamentos de LLM", "Ingeniería de prompts", "RAG", "Agentes de IA", "Ajuste fino", "Evaluación y LLMOps"],
"idioma": "español neutro (Chile)"   → corrida 1      |      "English"   → corrida 2 y modelo final
SISTEMA_ESTUDIANTE (corrida 2): "You are an expert assistant in generative AI. Answer in English, clearly and briefly."
n_entrenamiento 60 · n_examen 12 · epocas 3 · lote 4 · tasa_aprendizaje 5e-4 · lora_r 16 · estudiante HuggingFaceTB/SmolLM2-135M-Instruct
profesor y juez: gpt-6-luna
```

Único cambio respecto del original: el idioma pasó a inglés, por recomendación del profesor, porque SmolLM2 está entrenado mayoritariamente en inglés y entiende mal el español. El dominio, los temas y los hiperparámetros son los del profesor.

Por qué un modelo pequeño local: costo marginal por consulta ≈ 0, privacidad (las preguntas no salen del equipo) y disponibilidad sin internet ni GPU (270 MB, CPU). Qué se pierde frente a la API: calidad, conocimiento general y capacidad de razonamiento; con 135 M parámetros las respuestas son imprecisas, como muestran los resultados.

2. Datos del profesor

Indicador	Corrida 1 · español	Corrida 2 · inglés (final)
Pares de entrenamiento / preguntas de examen	60 / 12	60 / 12
Profesor al generar datos	78 llamadas · 9,001 tokens de entrada · 13,978 de salida · ≈ US$ 0.0079	78 llamadas · 8,617 tokens de entrada · 14,486 de salida · ≈ US$ 0.0081
Uso total del profesor y el juez en la corrida	102 llamadas · 16,888 tokens de entrada · 16,141 de salida · ≈ US$ 0.0098	102 llamadas · 17,128 tokens de entrada · 18,059 de salida · ≈ US$ 0.0107

Distribución por tema (corrida 2, entrenamiento): Agentes de IA 9; Ajuste fino 10; Evaluación y LLMOps 12; Fundamentos de LLM 10; Ingeniería de prompts 9; RAG 10. Examen: Agentes de IA 3; Ajuste fino 2; Fundamentos de LLM 2; Ingeniería de prompts 3; RAG 2.

Observación: el sorteo del examen (12 preguntas al azar) no incluyó ninguna pregunta de 'Evaluación y LLMOps', por lo que ese tema no se mide en la nota.

2.1 Revisión humana de respuestas del profesor

Leí 10 respuestas del profesor elegidas al azar (semilla 7) de datos/entrenamiento.jsonl, con el criterio de un ejecutivo que las usaría para decidir.

#	Tema	Pregunta (resumen)	Veredicto	Comentario
1	Evaluación y LLMOps	Probar si un chatbot RAG usa los documentos correctos	Correcta	Concreta y accionable: set de prueba, exactitud de citas, respuesta 'no sé', documentos desactualizados.
2	Evaluación y LLMOps	Salvaguardas antes de redactar sobre normas tributarias y laborales chilenas	Correcta (larga)	Cita fuentes chilenas reales (SII, Dirección del Trabajo) y revisión experta; supera el límite de 90 palabras.
3	Ajuste fino	Comparar un modelo ajustado con el equipo de soporte	Correcta	Piloto controlado, revisión ciega, umbrales y despliegue gradual.
4	Ingeniería de prompts	Qué es la ingeniería de prompts y por qué importa	Correcta	Definición clara y aterrizada a una empresa chilena.
5	Ajuste fino	Actualizar un modelo ajustado con procedimientos obsoletos	Correcta	Distingue bien ajuste fino de una base de conocimiento versionada (RAG).
6	RAG	RAG para procedimientos de seguridad en minería	Correcta	Ejemplo realista; incluye escalamiento a personal calificado.
7	Fundamentos de LLM	Error de creer que un LLM automatiza todo un flujo	Correcta	Buen ejemplo: resumir una factura no es validarla ni aprobarla.
8	Evaluación y LLMOps	Detectar caídas de calidad tras actualizar prompts o modelos	Correcta (larga)	Pruebas de regresión y umbrales; algo más larga que el límite.
9	Evaluación y LLMOps	Errores al usar la satisfacción de usuarios como métrica	Correcta	Señala que una respuesta confiada pero errónea puede puntuar bien.
10	Fundamentos de LLM	Tokens y ventana de contexto en resúmenes largos	Correcta	Explicación precisa del costo y del límite de contexto.

Resultado: 10 de 10 respuestas son correctas; ninguna requiere descarte. Dos superan levemente el límite de 90 palabras pedido al profesor. La calidad del profesor no es el cuello de botella: el techo lo pone la capacidad del estudiante.

Cambios a los prompts del profesor: solo el idioma (inglés). No se modificaron los prompts de generación ni del juez.

3. Línea base

Modelo base (sin entrenar)	Corrida 1 · español	Corrida 2 · inglés
Nota media del juez (1–10)	1,00	2,33
Aprobación (≥ 7)	0%	0%
Notas de las 12 preguntas	1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1	2, 3, 2, 3, 1, 3, 1, 1, 2, 3, 3, 4

En español el modelo base obtiene nota 1 en todas las preguntas: genera texto incoherente o mezcla idiomas. En inglés parte en 2,33: responde con fluidez, pero con errores de concepto. Esto confirma que el idioma es la principal limitación del estudiante.

3.1 Tres respuestas del modelo base comentadas (corrida 2)

Pregunta: How does fine-tuning compare with retrieval-augmented generation for answering questions about our company's policies and products?

Base (nota 2): Fine-tuning is a technique used to improve the accuracy of responses by adjusting parameters or features that influence how well they capture relevant information from the user's input data. In contrast, retrieval-augmented generation (RAG) focuses on generating answers based solely on existing knowledge and context provided during training phase. …

Comentario del juez: La respuesta describe incorrectamente RAG como dependiente del contexto de entrenamiento, no explica que recupera documentos actualizados al responder y queda incompleta. · Mi comentario: Fluida pero vaga: define el ajuste fino como 'ajustar parámetros' y se corta antes de comparar con RAG; no dice que RAG consulta documentos vigentes.

Pregunta: What are common prompt-writing mistakes that lead to vague, inaccurate, or overly confident answers?

Base (nota 3): When it comes to writing a response for a user's query, there are several common pitfalls that can lead to unclear, inaccurate, or overly confident responses:

*1. **Lack of specificity**: Providing too much information upfront without specifying the purpose or scope is crucial. Users often ask about specific details but fail to provide enough conte…*

Comentario del juez: Menciona la falta de especificidad y de evidencia, pero el primer punto es confuso, el segundo queda truncado y omite otros errores importantes como preguntas tendenciosas o exigir certeza sin pruebas. · Mi comentario: La mejor de las tres: empieza una lista estructurada y pertinente (falta de especificidad), pero se trunca y se contradice.

Pregunta: How do we measure whether a RAG system is retrieving the right information and giving reliable answers, rather than just sounding convincing?

Base (nota 2): Measuring the effectiveness of a RAG system can be challenging due to its subjective nature. However, there are several methods that can help evaluate the accuracy and reliability of a RAG system:

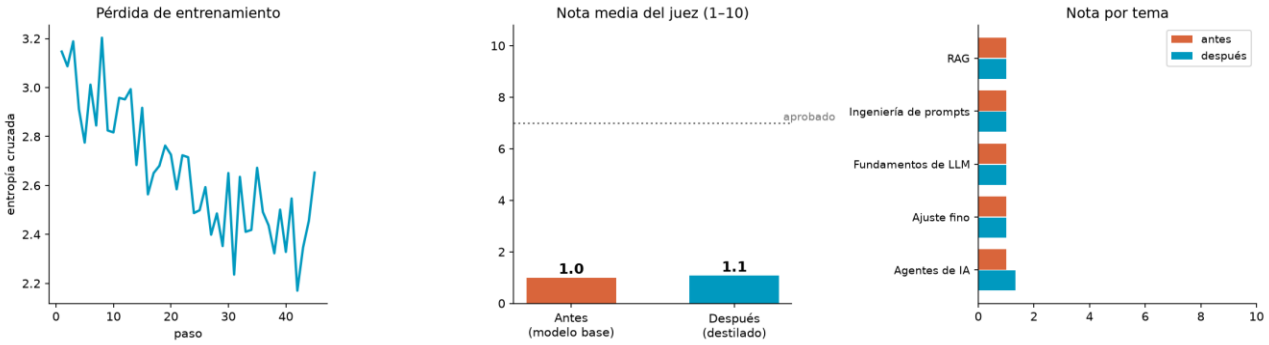
*1. **Data quality checks**: Verify if the data used for training the model has been properly cleaned, validated, and prepared before being fed into the …*

Comentario del juez: La respuesta propone métricas genéricas y controles de datos, pero no explica cómo evaluar la recuperación de evidencia, el respaldo y las citas de las respuestas, ni la abstención ante evidencia insuficiente; además, queda incompleta. · Mi comentario: Responde sobre la calidad de los datos de entrenamiento, que no es lo preguntado (evaluar la recuperación); no menciona precisión, recall ni citas.

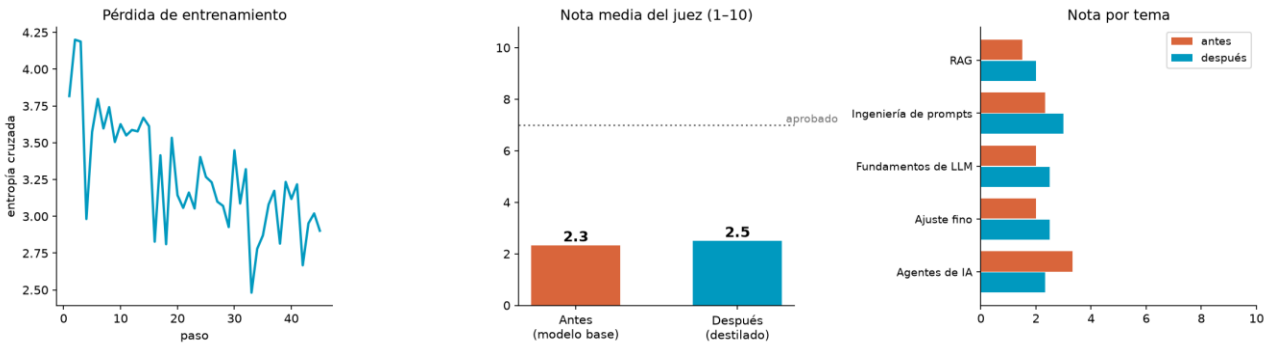
4. Experimentos

#	Cambio	n	ép.	lr	r	Nota antes	Nota después	Aprob.	Tiempo (min)	Observación
1	Original del profesor (español)	60	3	5e-4	16	1,00	1,08	0%	23.7 (ent. 19 min)	Pérdida 3.147 → 2.6524; no supera 2
2	Idioma → inglés	60	3	5e-4	16	2,33	2,50	0%	14.1 (ent. 10 min)	Pérdida 3.8173 → 2.902; supera 2
3	Colab GPU · español	60	3	5e-4	16	1,00	1,08	0%	2.2	no supera 2
4	Colab GPU · inglés	60	3	5e-4	16	2,08	2,83	0%	1.9	supera 2
5	Colab GPU · inglés + SmolLM2-360M	60	3	5e-4	16	4,08	4,58	0%	2.1	supera 2 · mejor nota
6	Modelo final (notebook, inglés)	60	3	5e-4	16	2,00	2,75	0%	—	Pérdida 3.8173 → 2.902

Corrida 1 · español (resultados.png):

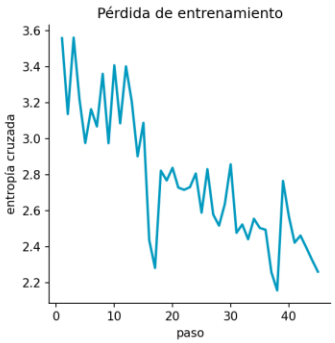


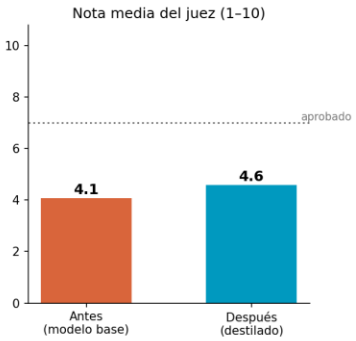
Corrida 2 · inglés (resultados.png):

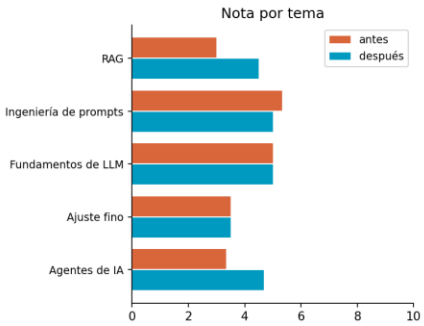


Lectura: cambiar el idioma es la variable que más pesa. En español el entrenamiento casi no mejora la nota (+0,08); en inglés la nota supera el umbral de 2 pedido por el profesor (2,50). La aprobación (≥ 7) sigue en 0 %: con 135 M parámetros, 60 ejemplos y 3 épocas, el modelo aprende el estilo de respuesta del profesor, pero no su exactitud.

SmolLM2-360M en Colab (resultados.png):







4.1 ¿Sobreajuste?

No hay evidencia de sobreajuste: la pérdida baja moderadamente (3.8173 → 2.902), sin llegar a valores cercanos a 0, y la nota sube levemente. El patrón es más bien de subajuste: pocos datos y un modelo muy pequeño. Para detectar sobreajuste habría que subir las épocas (por ejemplo a 8–10) y ver si la pérdida cae mucho mientras la nota se estanca. Además, el juez tiene variabilidad: la nota antes del mismo modelo base cambió entre corridas (2,33 en la corrida 2 y 2,00 en el notebook final), así que diferencias menores a ≈ 0,3 puntos son ruido.

4.2 CPU local vs. GPU en Colab

Las mismas dos configuraciones (español e inglés, SmolLM2-135M) se corrieron en el laptop (CPU i5, sin GPU) y en Google Colab (GPU Tesla T4):

	CPU local	GPU Colab (T4)
Entrenamiento LoRA (45 pasos)	19 min (español) · 10 min (inglés)	15 s (español) · 10 s (inglés)
Corrida completa	23.7 min · 14.1 min	2,2 min · 1,9 min
Español: nota antes → después	1,00 → 1,08	1,00 → 1,08
Inglés: nota antes → después	2,33 → 2,50	2,08 → 2,83
Inglés · SmolLM2-360M	no corrido (≈ 2–3× más lento que el 135M)	4,08 → 4,58

- **Velocidad:** la GPU entrena ≈ 60 veces más rápido (10 s contra ≈ 10 min). En la corrida completa la ventaja baja a ≈ 7–10 veces, porque la generación de datos y los juicios dependen de la API de OpenAI y no de la GPU.
- **Reproducibilidad:** las conclusiones se replican en ambos entornos. En español la nota es idéntica (1,00 → 1,08) y en inglés ambas superan 2 (2,50 local y 2,83 en Colab). Las cifras exactas difieren porque el profesor genera preguntas y examen nuevos en cada corrida.
- **Calidad:** el resultado no depende del hardware, sino del idioma y del tamaño del estudiante. La GPU solo acelera; no cambia la calidad con la misma configuración.
- **Estudiante más grande:** SmolLM2-360M (2,7 veces más parámetros) logra la mejor nota (4,58), aunque su aprobación bajó de 8 % a 0 % (un ítem pasó de 8 a 6), señal de que el entrenamiento no mejora todas las respuestas por igual.

5. Auditoría del juez

Califiqué a mano 10 ítems de salidas/examen_despues.jsonl (modelo final) con la misma rúbrica del juez: corrección, completitud y claridad; 7 = aceptable; inventos, incoherencia o repeticiones ≤ 2.

#	Tema	Pregunta	Juez	Mi nota	Dif.	Mi comentario
1	Ajuste fino	How does fine-tuning compare with retrieval-augmented	2	2	+0	Confunde ajuste fino con evaluación; no explica RAG.

		generation for answering q…				
2	Ingeniería de prompts	What are common prompt-writing mistakes that lead to vague, inaccurate, or overl…	5	4	+1	Lista con ideas sueltas y una contradicción ('not enough context is needed').
3	RAG	How do we measure whether a RAG system is retrieving the right information and g…	4	4	+0	Mezcla métricas válidas con irrelevantes (tiempos).
4	Agentes de IA	Can an AI agent reliably handle supplier invoices and purchase approvals, or sho…	3	3	+0	Confunde aprobación de compras con autorización de clientes.
5	Fundamentos de LLM	Can an LLM understand a customer's intent, or is it mainly matching patterns in …	2	2	+0	Divaga y se trunca; no aborda el caso del banco.
6	Ingeniería de prompts	When should we use a prompt template instead of writing a new prompt for every t…	4	3	+1	Recomienda plantillas de forma demasiado general.
7	Ingeniería de prompts	How could our customer service team use prompts to draft helpful responses in Ch…	1	1	+0	Fuera de tema (autos, frases en español mal escritas).
8	RAG	What infrastructure and ongoing costs should we expect if we deploy RAG for a fe…	2	2	+0	No habla de costos; afirmaciones dudosas.
9	Ajuste fino	What kinds of business data are useful for fine-tuning, and how much high-qualit…	3	2	+1	Algunos tipos de datos razonables, sin cantidades; truncada.
10	Fundamentos de LLM	What is the difference between an LLM's training data and the information it can…	3	2	+1	Confunde datos de entrenamiento con acceso a documentos.

Métrica de acuerdo juez–humano	Valor
Nota media juez / humano	2,90 / 2,50
Sesgo medio (juez − humano)	+0,40
Error absoluto medio	0,40
Acuerdo exacto	60%
Acuerdo dentro de ±1 punto	100%
Correlación de Pearson	0,91
Aprobación (≥ 7) juez / humano	0 % / 0 %

El juez es confiable para ordenar las respuestas (alta correlación y acuerdo ±1 en todos los ítems), pero es levemente más generoso: en 4 de 10 ítems da un punto más. Los desacuerdos se concentran en respuestas fluidas y bien estructuradas, pero con errores de concepto (ítems 2, 6, 9 y 10): el juez premia en parte la forma. También comenta en español respuestas en inglés, sin que eso afecte la nota.

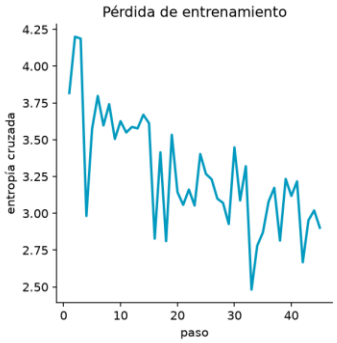
Cambio propuesto al prompt del juez (función evaluar de destila.py): agregar 'una respuesta fluida con errores conceptuales no debe superar 3' y pedir que identifique explícitamente el error principal antes de poner la nota; así se reduce el premio a la forma.

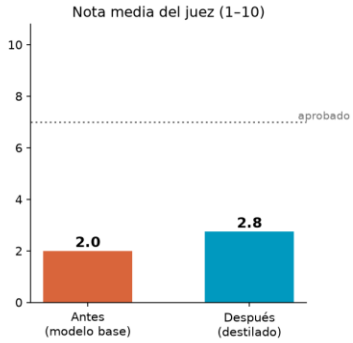
6. Modelo final y demostración

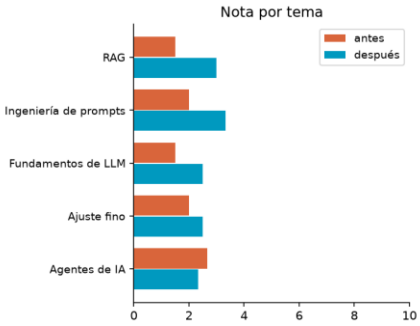
	Antes (base)	Después (destilado)
Nota media (1–10)	2,00	2,75
Aprobación (≥ 7)	0%	0%
Pérdida de entrenamiento	3.8173	2.902

Nota por tema (después): Agentes de IA 2,33; Ajuste fino 2,50; Fundamentos de LLM 2,50; Ingeniería de prompts 3,33; RAG 3,00.

Configuración final: la del profesor, en inglés (60 pares, 3 épocas, lr 5e-4, r 16). Se entrenó ejecutando el notebook taller_destilacion.ipynb; el adaptador LoRA quedó en salidas/checkpoint.







6.1 Cinco preguntas nuevas, lado a lado (salidas/demo.md)

Tipo	Pregunta	Modelo base	Destilado
dentro	What is a hallucination in a large language model, and how can a company reduce it?	In the context of large-scale language models like Google's DeepMind's AlphaGo or IBM's IBM Watson, hallucinations refer to vivid mental images that occur when a human criticizes or judges another person based on their performance. These hallucinations often i…	A hallucination occurs when the output of a machine-learning model contains false or misleading information—such as what happened instead of who did it. For example: “I saw a man wearing a red shirt at the store.” A solution would remove irrelevant data from i…
dentro	When should a company use RAG instead of fine-tuning a model?	A company might consider using RAG (Reduced Average Rating) when they want to improve the accuracy or reliability of their models by reducing the number of parameters used during training. This approach is often recommended for applications where high precisio…	Use RAG when:
dentro	What is a context window and why does it matter for business documents?	A context window refers to the frame of information that appears on each page or screen during the creation process. It's essentially the visual representation of what will be displayed next when you click on a particular link, button, or other element within …	A context window (CV) represents the current document or conversation with someone else—for example, when you’re responding to a customer inquiry; asking about a policy change; sending a report; or updating sales data. It helps track what happened during that …
fuera	What is the capital of Australia?	The capital city of Australia is Canberra.	The capital city of Australia is Canberra (pronounced kah-tee). It’s located on the Australian mainland at the foot of the Great Dividing Range. The capital has a population of over 2 million people—about one-third of all Australians live there.
fuera	Give me a short recipe for pancakes.	Sure! Here's a simple yet delicious pancake recipe: 1. **Ingredients:** - 2 cups all-purpose flour (plus more if needed) - 3/4 cup granulated sugar	Start with 1 cup of milk or cream (or use your own). Add one teaspoon of sugar; whisk until smooth—about two minutes per pancake. Top each with fresh fruit such as strawberries, blueberries, or chopped nuts. Serve warm on a popsicle stick.

		- 1 teaspoon baking powder - 1/2 teaspoon salt - 1 tablespoon unsweetened cocoa powder - 1 egg - 1/2 cup milk o…	

6.2 Limitaciones

- **Alucinaciones:** inventa definiciones con seguridad (en la demostración de la corrida 2, el destilado define LoRA como 'Low-Rate Automatic Translation').
- **Repeticiones y respuestas truncadas:** repite frases o se corta por el límite de 120 tokens de respuesta.
- **Idioma:** en español no produce respuestas útiles; en inglés es fluido, pero impreciso.
- **Alcance:** fuera del dominio responde como un modelo genérico, sin advertir que está fuera de su alcance.

Mitigación: más datos (cientos o miles de pares), un estudiante algo mayor, más épocas vigilando el sobreajuste, y ejemplos que enseñen a responder 'no lo sé' fuera del dominio.

6.3 Propuesta: cambiar el estudiante a SmolLM2-360M (corre en CPU)

Como sugirió el profesor, propongo SmolLM2-360M-Instruct como estudiante. Sigue corriendo en CPU (≈ 720 MB; se cambia con python destila.py --estudiante HuggingFaceTB/SmolLM2-360M-Instruct) y en la prueba de Colab obtuvo 4,08 → 4,58: un 60 % más que el 135M (2,83 en la misma prueba). En el laptop el entrenamiento tardaría ≈ 2–3 veces más (≈ 25–30 min), un costo aceptable. El modelo final entregado se mantiene en 135M para respetar la indicación de correr el taller tal como está.

7. Reflexión: ¿destilar o seguir usando la API?

Costo. Enseñar al estudiante costó centavos: una corrida completa en inglés usó 102 llamadas · 17,128 tokens de entrada · 18,059 de salida · ≈ US$ 0.0107, y las cinco corridas reales (local y Colab) sumaron menos de US$ 0,06. Una vez destilado, cada consulta al modelo local tiene un costo marginal cercano a cero, mientras que con la API se paga siempre. Destilar se justifica cuando el volumen de consultas repetitivas es alto.

Privacidad. El modelo local responde sin enviar datos fuera del equipo, algo clave en banca, salud o AFP. Pero durante la destilación las preguntas sí viajan a la API, por lo que los datos de entrenamiento no deben contener información confidencial. El propio taller mostró este riesgo: el notebook original dejaba la clave de la API escrita en su salida.

Calidad. Es el punto débil. El estudiante de 135 M pasó de 2,00 a 2,75 sobre 10 y ninguna respuesta llegó al nivel aceptable (7). Aprendió el tono y la estructura del profesor, pero no su exactitud, e inventa definiciones con seguridad. El idioma pesó más que cualquier ajuste (en español no superó 1,1) y el tamaño también importa: el 360M llegó a 4,58. La GPU acelera unas 60 veces el entrenamiento, pero no mejora la calidad. Además, el juez es otro LLM, levemente generoso con las respuestas fluidas, por lo que hay que auditarlo.

Mantenimiento y licencias. El conocimiento queda congelado al momento de destilar y hay que repetir el proceso cuando el dominio cambia. SmolLM2 tiene licencia Apache 2.0, pero los términos de OpenAI restringen usar sus salidas para desarrollar modelos que compitan con OpenAI: el uso educativo o interno es razonable; un producto comercial requiere revisión legal.

Conclusión. Para responder a ejecutivos, hoy conviene seguir con la API, o con un estudiante local mayor (1–4 B parámetros, con GPU y miles de ejemplos, como en el repositorio slm-autonomo), hasta alcanzar la calidad mínima aceptable. La destilación a un modelo diminuto sirve para aprender el método y para tareas acotadas y de bajo

riesgo (clasificar, reformular, preguntas frecuentes), siempre con supervisión humana. Destilar conviene cuando el dominio es acotado, el volumen es alto y los datos son sensibles; la API conviene cuando la calidad es crítica o el volumen es bajo.

Anexos

A. Cambios en destila.py y archivos agregados

- **destila.py:** "idioma": "español neutro (Chile)" → "English" (corrida 2 y modelo final).
- **destila.py:** SISTEMA_ESTUDIANTE → "You are an expert assistant in generative AI. Answer in English, clearly and briefly."
- **destila.py y notebook:** la pregunta de demostración de correr_todo y las dos del notebook, traducidas al inglés.
- **taller_destilacion.ipynb:** la celda 1 muestra cfg sin la api_key (seguridad).
- **Agregados:** aplicar_ingles.py (aplica los cambios anteriores), demo.py (5 preguntas nuevas), corridas/ (resultados locales y de Colab), colab_taller_destilacion_gpu.ipynb, RESULTADOS.md y .gitignore.

B. Problemas técnicos y cómo los resolví

Problema	Solución
Python 3.14 fuera del rango soportado (3.10–3.13)	Entorno virtual con py -3.12
Riesgo de bloqueo de archivos por Dropbox	Trabajo en C:\slm\taller-a, fuera de la carpeta sincronizada
La clave no quedaba guardada en .env	Guardar con Ctrl+S y verificar (sin mostrar el valor) que la línea no estuviera vacía ni tuviera comillas
Entrenamiento lento en CPU (19 min en la corrida 1)	Cerrar programas; corrida paralela en Google Colab con GPU
destila.py sobrescribe salidas/ en cada corrida	Copia de datos/ y salidas/ de cada corrida en corridas/<nombre>/
El notebook original muestra cfg completo en la celda 1, incluida la api_key: al ejecutarlo, la clave quedaba escrita en la salida	La celda muestra cfg con la clave oculta ('***'); escaneo de todo el entregable para confirmar que no hay claves fuera de .env
Prueba --sin-internet (simulada)	Se usó solo para validar la instalación (nota 1 → 9,33); no se entrega porque no usa la API

C. Declaración de uso de asistentes de IA

Usé Claude Code (Anthropic) para preparar el entorno, ejecutar las corridas locales, armar el notebook de Colab, organizar los resultados y redactar este informe, incluida una propuesta de calificación para la revisión del profesor y la auditoría del juez, que revisé y validé. Usé GitHub Copilot en VS Code como apoyo. Las decisiones del trabajo y la versión final son de mi responsabilidad.